

Facteurs associés à l'accident vasculaire cérébral chez les adultes : une analyse multivariée

Analyse transversale du jeu de données de prédiction des AVC de Kaggle

Jiahui YI / Jade YI

2026-09-20

Table des matières

1	Introduction et objectifs	2
1.1	Objectifs de l'analyse	2
1.2	Méthode	2
2	Source des données	2
2.1	Structure initiale	3
2.1.1	Répartition de l'AVC dans le fichier brut	3
3	Évaluation initiale de la qualité des données	5
3.1	Valeurs manquantes	5
3.2	Valeurs incohérentes ou improbables	5
4	Définition de la population analytique et préparation des données	7
4.0.1	Mise en perspective avec les données françaises	9
4.0.2	Préparation des variables	9
5	Méthodes statistiques	10
5.1	Représentation conceptuelle des relations hypothétiques (DAG)	10
6	Résultats	12
6.1	Description de la population	12
6.2	Modèle multivarié	13
6.3	Analyse de sensibilité : écrêtement du BMI	17
6.4	Représentation graphique des résultats	17

7	Discussion	21
7.1	Confrontation aux hypothèses	21
7.2	Limites	22
8	Conclusion	22

1 Introduction et objectifs

Cette analyse observationnelle est rapportée conformément aux recommandations STROBE (Elm et al. 2007).

1.1 Objectifs de l'analyse

L'objectif principal est d'étudier les facteurs associés à la présence d'un antécédent d'AVC chez les adultes de ce jeu de données.

1.2 Méthode

L'analyse repose sur une régression logistique multivariée standard, avec l'AVC (oui/non) comme variable dépendante. Les résultats seront exprimés sous forme d'*odds ratios* (OR) ajustés, accompagnés de leur intervalle de confiance à 95 %.

Il s'agit d'une analyse observationnelle : les associations mises en évidence ne permettent pas, à elles seules, de conclure à un lien causal.

2 Source des données

Les données proviennent du jeu de données public *Stroke Prediction Dataset*, diffusé sur la plateforme Kaggle (fichier `healthcare-dataset-stroke-data.csv`). Chaque ligne correspond à un individu, décrit par :

- des caractéristiques démographiques (âge, sexe, statut marital, type d'emploi, lieu de résidence) ;
- des caractéristiques cliniques (hypertension, maladie cardiaque, glycémie moyenne, indice de masse corporelle) ;
- un comportement (statut tabagique) ;
- la présence ou non d'un antécédent d'AVC.

```
donnees <- read_csv(
  "../data/raw/healthcare-dataset-stroke-data.csv",
  na = c("", "NA", "N/A")
)
```

2.1 Structure initiale

```
n_total <- nrow(donnees)
n_avc   <- sum(donnees$stroke == 1)
n_non   <- n_total - n_avc
prop_avc <- n_avc / n_total
```

Le fichier brut contient 5110 individus et 12 variables. Chaque id est-il unique ? Oui.

2.1.1 Répartition de l'AVC dans le fichier brut

```
donnees |>
  count(stroke) |>
  mutate(
    AVC = if_else(stroke == 1, "Oui", "Non"),
    Proportion = scales::percent(n / sum(n), accuracy = 0.01)
  ) |>
  select(AVC, Effectif = n, Proportion) |>
  knitr::kable()
```

AVC	Effectif	Proportion
Non	4861	95.13%
Oui	249	4.87%

```
donnees |>
  count(stroke) |>
  mutate(
    AVC = if_else(stroke == 1, "Oui", "Non"),
    proportion = n / sum(n)) |>
  ggplot(aes(x = AVC, y = proportion)) +
  geom_col(width = 0.6) +
```

```
geom_text( aes(label = scales::percent(proportion, accuracy = 0.1)),
  vjust = -0.5) +
scale_y_continuous(
  labels = scales::percent,
  limits = c(0, 1)) +
labs(x = "AVC", y = "Proportion") +
theme_minimal()
```




FIGURE 1 : Répartition du statut AVC dans le fichier brut

Dans le fichier brut, 249 individus sur 5110 présentent un statut AVC positif, soit 4.9%. Le rapport est d'environ 19.5 individus sans AVC pour un individu avec AVC.

Cette proportion décrit uniquement la composition du jeu de données brut et ne constitue pas une estimation de la prévalence de l'AVC dans une population définie.

3 Évaluation initiale de la qualité des données

3.1 Valeurs manquantes

```
donnees |>
  summarise(across(everything(), ~ sum(is.na(.)))) |>
  pivot_longer(everything(), names_to = "Variable", values_to = "n_manquant") |>
  filter(n_manquant > 0) |>
  mutate(Pourcentage = scales::percent(n_manquant / nrow(donnees), accuracy = 0.1)) |>
  rename(`Valeurs manquantes` = n_manquant) |>
  knitr::kable()
```

Variable	Valeurs manquantes	Pourcentage
bmi	201	3.9%

Seule la variable `bmi` comporte des valeurs manquantes au sens strict (codées `NA`). Les autres variables ne présentent aucune valeur manquante déclarée.

Cas particulier de `smoking_status`. Cette variable comporte une modalité "Unknown", qui correspond fonctionnellement à une information manquante mais qui n'est pas codée comme `NA` dans le fichier source. Cette modalité n'est pas traitée dans cette section ; elle sera examinée séparément lors de la préparation des données pour la modélisation.

À ce stade, nous nous limitons à documenter l'ampleur des valeurs manquantes de `bmi`. Leur traitement (exclusion ou imputation simple) sera décidé dans la section consacrée à la préparation des données pour la modélisation, en fonction de la stratégie retenue pour l'analyse multivariée.

3.2 Valeurs incohérentes ou improbables

```
donnees |>
  reframe(across(
    c(age, bmi, avg_glucose_level),
    ~ c(min(.x, na.rm = TRUE),
        quantile(.x, 0.25, na.rm = TRUE),
        median(.x, na.rm = TRUE),
        quantile(.x, 0.75, na.rm = TRUE),
        max(.x, na.rm = TRUE))
```

```

)) |>
mutate(Statistique = c("Min", "Q1", "Médiane", "Q3", "Max"), .before = 1) |>
knitr::kable(digits = 1)

```

Statistique	age	bmi	avg_glucose_level
Min	0.1	10.3	55.1
Q1	25.0	23.5	77.2
Médiane	45.0	28.1	91.9
Q3	61.0	33.1	114.1
Max	82.0	97.6	271.7

L'examen de la distribution des variables quantitatives ne révèle pas de valeur impossible évidente ne révèle pas de valeur impossible évidente (âge négatif, BMI ou glycémie nul, etc.). Deux points méritent toutefois d'être signalés :

- **Âges non entiers.** 115 individus ont un âge non entier, tous âgés de moins de 2 ans. Il s'agit vraisemblablement d'un encodage de l'âge en fraction d'année chez les nourrissons, et non d'une erreur de saisie.
- **BMI extrême.** La valeur maximale de BMI (97.6) est cliniquement très élevée. Cette valeur sera examinée individuellement lors de la préparation des données, sans être exclue à ce stade.

```

donnees |> count(gender) |> knitr::kable()

```

gender	n
Female	2994
Male	2115
Other	1

```

donnees |>
  filter(
    (age < 18 & ever_married == "Yes") |
    (age < 18 & work_type %in% c("Govt_job", "Private", "Self-employed"))
  ) |>
  select(id, age, ever_married, work_type)

```

```

# A tibble: 152 x 4
  id    age ever_married work_type

```

	<dbl>	<dbl>	<chr>	<chr>
1	16523	8	No	Private
2	26325	14	No	Govt_job
3	70970	17	No	Self-employed
4	23462	17	No	Private
5	54975	7	No	Self-employed
6	7351	13	No	Private
7	43134	16	No	Private
8	31145	17	No	Private
9	54182	16	No	Private
10	16575	17	No	Private

i 142 more rows

La variable `gender` ne compte qu'une seule observation "Other", effectif insuffisant pour l'analyse; cette observation sera exclue.

Aucune incohérence supplémentaire évidente n'a été identifiée lors de l'examen des combinaisons âge/statut marital et âge/type d'emploi.

Stratégie retenue. Le BMI maximal reste cliniquement possible : aucune modification n'est appliquée à ce stade. L'analyse sera d'abord réalisée sur les données non écrêté après imputation médiane, puis en analyse de sensibilité après écrêtement (*winsorizing*) du BMI aux 2,5 et 97,5 percentiles. Les deux résultats seront comparés.

4 Définition de la population analytique et préparation des données

L'analyse porte uniquement sur les adultes : les individus âgés de moins de 18 ans sont exclus, car le mécanisme et les facteurs de risque de l'AVC diffèrent fortement chez l'enfant, et plusieurs variables (`work_type`, `ever_married`) n'ont pas de sens pour cette population. L'unique observation `gender = "Other"` est également exclue, son effectif étant insuffisant pour être traitée comme catégorie à part entière.

La modalité `Never_worked` de `work_type` ne comprend que cinq individus dans la population adulte et aucun cas d'AVC. Cette configuration entraîne une estimation instable du coefficient correspondant dans la régression logistique en raison d'un phénomène de séparation. Compte tenu de cet effectif extrêmement faible, ces cinq observations sont exclues de l'analyse principale.

```
donnees_adultes_brut <- donnees |>
  filter(age >= 18)

donnees_adultes <- donnees_adultes_brut |>
```

```

filter(gender != "Other",work_type != "Never_worked" ) |>
mutate(
  gender = droplevels(as.factor(gender)),
  work_type = droplevels(as.factor(work_type))
)

n_adultes <- nrow(donnees_adultes_brut)
n_avc_adultes <- sum(donnees_adultes_brut$stroke == 1)
prop_avc_adultes <- n_avc_adultes / n_adultes
n_exclus_age <- sum(donnees$age < 18)
n_exclus_gender <- sum(donnees$age >= 18 & donnees$gender == "Other")
n_exclus_never_worked<- sum(donnees_adultes_brut$work_type=="Never_worked")
n_analyse <- nrow(donnees_adultes)

tibble::tibble(
  Étape = c("Fichier initial", "Âge < 18", "Genre = Other",
            "Never worked", "Échantillon final"),
  Exclus = c(NA, n_exclus_age, n_exclus_gender, n_exclus_never_worked, NA),
  Restants = c(n_total, n_total - n_exclus_age,
               n_total - n_exclus_age - n_exclus_gender,n_analyse,
               n_analyse)) |>
knitr::kable(
  col.names = c("Étape", "Nombre exclu", "Effectif restant"),
  format.args = list(big.mark = " ")
)

```

Étape	Nombre exclu	Effectif restant
Fichier initial	NA	5 110
Âge < 18	856	4 254
Genre = Other	1	4 253
Never worked	5	4 248
Échantillon final	NA	4 248

Sur les 5110 individus du fichier initial, 856 sont exclus en raison d'un âge inférieur à 18 ans, 1 en raison de la modalité `gender = "Other"` et 5 en raison de la modalité très rare `work_type = "Never_worked"`, soit une population analytique finale de 4248 individus.

Parmi les 4254 individus âgés de 18 ans ou plus, 247 présentent un statut AVC positif, soit 5.8%.

4.0.1 Mise en perspective avec les données françaises

À titre de repère externe, Santé publique France estime qu'environ 2,0 % de la population adulte française avait un antécédent d'AVC au 1er janvier 2023 (Gabet et al. 2025).

Dans le présent jeu de données, la proportion d'individus adultes présentant un statut AVC positif est de 5.8%.

Ces deux valeurs ne sont toutefois pas directement comparables. L'estimation de Santé publique France concerne une population nationale définie, tandis que le mode de constitution, la population source et la représentativité du jeu de données utilisé ici ne sont pas documentés.

La définition et la temporalité de la variable `stroke` ne permettent pas non plus de l'assimiler sans réserve à l'indicateur utilisé par Santé publique France. Cet écart souligne principalement que la proportion observée dans ce jeu de données ne peut pas être directement transposée à la population adulte française.

En l'absence d'informations sur l'échantillonnage, il n'est pas possible d'évaluer formellement la représentativité externe du jeu de données.

4.0.2 Préparation des variables

Analyse principale et analyse de sensibilité. Le BMI non écrêté, après imputation des valeurs manquantes par la médiane, sera utilisé dans l'analyse principale. Une analyse de sensibilité sera réalisée avec une version écrêtée du BMI aux 2,5 et 97,5 percentiles afin d'évaluer si les estimations sont sensibles aux valeurs extrêmes.

```
mediane_bmi <- median(donnees_adultes$bmi, na.rm = TRUE)
seuil_bas   <- quantile(donnees_adultes$bmi, 0.025, na.rm = TRUE)
seuil_haut  <- quantile(donnees_adultes$bmi, 0.975, na.rm = TRUE)

donnees_adultes <- donnees_adultes |>
  mutate(
    bmi = if_else(is.na(bmi), mediane_bmi, bmi),
    bmi_wins = case_when(
      bmi < seuil_bas ~ seuil_bas,
      bmi > seuil_haut ~ seuil_haut,
      TRUE ~ bmi
    ),
    stroke = factor(stroke, levels = c(0, 1), labels = c("Non", "Oui")),
    hypertension = factor(hypertension, levels = c(0, 1), labels = c("Non", "Oui")),
    heart_disease = factor(heart_disease, levels = c(0, 1), labels = c("Non", "Oui"))
  )
```

5 Méthodes statistiques

L'association entre chaque facteur et la survenue d'un AVC est d'abord décrite en analyse univariée (tableau 1), puis évaluée par régression logistique multivariée, l'AVC (oui/non) étant la variable dépendante. Les résultats sont exprimés en *odds ratios* (OR) ajustés avec leur intervalle de confiance à 95 %. Le seuil de significativité est fixé à 0,05.

Le modèle multivarié inclut l'ensemble des variables décrites au tableau 1, afin de décrire les associations conjointes avec l'AVC dans cet échantillon. Cette sélection n'est pas dérivée d'un DAG : les coefficients ne sont pas interprétés comme des effets causaux, et chaque OR est lu comme une association ajustée sur les autres covariables. Deux analyses de sensibilité sont réalisées : l'une sur le BMI écrêté aux 2,5 et 97,5 percentiles (par opposition au BMI non écrêté du modèle principal), l'autre en exprimant la glycémie moyenne par tranche de 10 mg/dL plutôt que par unité.

Toutes les analyses sont réalisées avec R, à l'aide des packages `tidyverse`, `gtsummary` et `broom`.

5.1 Représentation conceptuelle des relations hypothétiques (DAG)

Le schéma ci-dessous est un support conceptuel, présenté à titre illustratif. Il représente des relations hypothétiques, fondées sur des connaissances générales et non sur une revue systématique de la littérature, et sert uniquement à illustrer le rôle central de l'âge. Il n'a pas servi à sélectionner les covariables du modèle, ni à estimer un effet causal, ni à définir un ensemble minimal d'ajustement. Le statut marital et le type d'emploi y figurent comme variables corrélées à l'âge, sans flèche vers l'AVC : ils sont conservés dans le modèle dans un but descriptif, par cohérence avec le tableau 1.

```
coords <- list(
  x = c(age = 2, hypertension = 3, heart_disease = 3, ever_married = 3,
        work_type = 3, gender = 2, smoking = 3, avg_glucose_level = 4,
        bmi = 4, stroke = 5),
  y = c(age = 3, hypertension = 4, heart_disease = 5, ever_married = 2,
        work_type = 1, gender = 0, smoking = 0.5, avg_glucose_level = 3.5,
        bmi = 2.5, stroke = 3))

dag_avc <- dagify(
  stroke ~ age + hypertension + heart_disease + avg_glucose_level + bmi + smoking + gender,
  hypertension ~ age + bmi + avg_glucose_level,
  heart_disease ~ age,
  avg_glucose_level ~ age + bmi,
  bmi ~ age,
```

```

ever_married ~ age,
work_type ~ age,
smoking ~ gender,
coords = coords,
labels = c(
  stroke = "AVC",
  age = "Âge",
  gender = "Sexe",
  hypertension = "Hypertension",
  heart_disease = "Maladie\ncardiaque",
  avg_glucose_level = "Glycémie",
  bmi = "IMC",
  smoking = "Tabac",
  ever_married = "Statut\anmarital",
  work_type = "Type\nd'emploi"
)
)

ggplot(dag_avc, aes(x = x, y = y, xend = xend, yend = yend)) +
  geom_dag_edges() +
  geom_label(aes(label = label), na.rm = TRUE, size = 3.2) +
  theme_dag()

```




FIGURE 2 : Représentation conceptuelle des relations hypothétiques entre les variables

6 Résultats

6.1 Description de la population

Le tableau 1 décrit les caractéristiques de la population analytique selon la survenue ou non d'un AVC.

```
donnees_adultes |>
  select(
    stroke, age, gender, hypertension, heart_disease,
    ever_married, work_type, Residence_type,
    avg_glucose_level, bmi, smoking_status
  ) |>
  tbl_summary(
    by = stroke,
    label = list(
```

```

age ~ "Âge (années)",
gender ~ "Sexe",
hypertension ~ "Hypertension",
heart_disease ~ "Maladie cardiaque",
ever_married ~ "Déjà marié(e)",
work_type ~ "Type d'emploi",
Residence_type ~ "Lieu de résidence",
avg_glucose_level ~ "Glycémie moyenne (mg/dL)",
bmi ~ "IMC (kg/m²)",
smoking_status ~ "Statut tabagique"
),
statistic = list(
  all_continuous() ~ "{mean} ({sd})",
  all_categorical() ~ "{n} ({p}%)"
),
digits = all_continuous() ~ 1
) |>
add_p(test = list(all_continuous() ~ "t.test")) |>
add_overall() |>
modify_header(label ~ "**Variable**") |>
modify_caption("**Tableau 1.** Caractéristiques de la population selon le statut AVC")

```

Les variables continues sont présentées en moyenne (écart-type) et comparées par test t de Student ; les variables catégorielles sont présentées en effectif (pourcentage) et comparées par test du χ^2 (ou test exact de Fisher en cas d'effectifs attendus trop faibles).

6.2 Modèle multivarié

Un modèle de régression logistique multivariée est ajusté, avec la survenue d'un AVC comme variable dépendante. Les covariables incluses sont l'âge, le sexe, l'hypertension, la maladie cardiaque, le statut marital, le type d'emploi, le lieu de résidence, la glycémie moyenne, l'IMC (non écrêté, après imputation par la médiane) et le statut tabagique — soit l'ensemble des variables décrites au tableau 1.

```

modele_principal <- glm(
  stroke ~ age + gender + hypertension + heart_disease + ever_married +
    work_type + Residence_type + avg_glucose_level + bmi + smoking_status,
  data = donnees_adultes,
  family = binomial(link = "logit")
)

```

Variable	Overall N = 4,248 ¹	Non N = 4,001 ¹	Oui N = 247 ¹	p-value ²
Âge (années)	50.2 (17.8)	49.1 (17.5)	68.2 (11.6)	<0.001
Sexe				0.2
Female	2,572 (61%)	2,433 (61%)	139 (56%)	
Male	1,676 (39%)	1,568 (39%)	108 (44%)	
Hypertension				<0.001
Non	3,751 (88%)	3,570 (89%)	181 (73%)	
Oui	497 (12%)	431 (11%)	66 (27%)	
Maladie cardiaque				<0.001
Non	3,973 (94%)	3,773 (94%)	200 (81%)	
Oui	275 (6.5%)	228 (5.7%)	47 (19%)	
Déjà marié(e)	3,353 (79%)	3,133 (78%)	220 (89%)	<0.001
Type d'emploi				0.010
Govt_job	651 (15%)	618 (15%)	33 (13%)	
Private	2,790 (66%)	2,641 (66%)	149 (60%)	
Self-employed	807 (19%)	742 (19%)	65 (26%)	
Lieu de résidence				0.3
Rural	2,084 (49%)	1,971 (49%)	113 (46%)	
Urban	2,164 (51%)	2,030 (51%)	134 (54%)	
Glycémie moyenne (mg/dL)	108.5 (47.8)	107.0 (46.4)	133.1 (61.9)	<0.001
IMC (kg/m ²)	30.4 (7.1)	30.4 (7.2)	30.3 (5.8)	0.7
Statut tabagique				0.013
Unknown	860 (20%)	815 (20%)	45 (18%)	
formerly smoked	859 (20%)	789 (20%)	70 (28%)	
never smoked	1,749 (41%)	1,659 (41%)	90 (36%)	
smokes	780 (18%)	738 (18%)	42 (17%)	

¹Mean (SD) ; n (%)

²Welch Two Sample t-test ; Pearson's Chi-squared test

```
tbl_regression(modele_principal, exponentiate = TRUE) |>
  modify_header(label ~ "**Variable**") |>
  modify_caption("**Tableau 2.** Odds ratios ajustés (IC 95%) de l'association avec l'AVC")
```

Après ajustement, l'âge (OR = 1.08 par année, IC 95 % 1.07–1.09, $p < 0,001$), l'hypertension (OR = 1.49, IC 95 % 1.07–2.05, $p = 0,015$) et la glycémie moyenne (OR = 1.00 par mg/dL, IC 95 % 1.00–1.01, $p < 0,001$) sont significativement et indépendamment associées à l'AVC.

Les autres covariables ne sont pas significativement associées à l'AVC dans ce modèle ajusté : le sexe, la maladie cardiaque, le statut marital, le type d'emploi, le lieu de résidence, l'IMC et le statut tabagique.

La maladie cardiaque, significativement associée à l'AVC en analyse descriptive et comparaisons bivariées (tableau 1), ne l'est plus après ajustement (OR = 1.32, IC 95 % 0.90–1.90, $p = 0.15$). Cette atténuation suggère que l'association observée en univariée est en partie expliquée par l'âge, les patients porteurs d'une maladie cardiaque étant en moyenne plus âgés.

Cas particulier de la glycémie moyenne. Bien que statistiquement significatif, l'OR de `avg_glucose_level` est très proche de 1 (1,00 par unité de mg/dL). Cela reflète l'échelle de la variable : un écart de 1 mg/dL est cliniquement négligeable, alors qu'un écart de 20 ou 30 mg/dL est cliniquement pertinent. L'ampleur réelle de l'effet est donc sous-estimée visuellement par cet OR unitaire.

```
donnees_adultes <- donnees_adultes |>
  mutate(glucose_10 = avg_glucose_level / 10)

modele_glucose <- glm(
  stroke ~ age + gender + hypertension + heart_disease + ever_married +
    work_type + Residence_type + glucose_10 + bmi + smoking_status,
  data = donnees_adultes,
  family = binomial(link = "logit")
)

or_glucose <- exp(coef(modele_glucose)["glucose_10"])
ic_glucose <- exp(confint.default(modele_glucose)["glucose_10", ])
```

Exprimé pour une augmentation de 10 mg/dL, l'effet de la glycémie moyenne devient plus interprétable : OR = 1.04 (IC 95 % 1.02–1.07). Les coefficients des autres covariables sont strictement identiques à ceux du modèle principal, seule l'échelle de `avg_glucose_level` étant modifiée.

Variable	OR	95% CI	p-value
age	1.08	1.07, 1.09	<0.001
gender			
Female	—	—	
Male	1.03	0.78, 1.37	0.8
hypertension			
Non	—	—	
Oui	1.49	1.07, 2.05	0.015
heart_disease			
Non	—	—	
Oui	1.32	0.90, 1.90	0.15
ever_married			
No	—	—	
Yes	0.82	0.53, 1.30	0.4
work_type			
Govt_job	—	—	
Private	1.16	0.78, 1.76	0.5
Self-employed	0.79	0.51, 1.27	0.3
Residence_type			
Rural	—	—	
Urban	1.09	0.83, 1.43	0.5
avg_glucose_level	1.00	1.00, 1.01	<0.001
bmi	1.00	0.98, 1.02	0.9
smoking_status			
formerly smoked	—	—	
never smoked	0.82	0.58, 1.16	0.3
smokes	1.12	0.73, 1.70	0.6
Unknown	0.93	0.61, 1.39	0.7

Abbreviations : CI = Confidence Interval, OR = Odds Ratio

6.3 Analyse de sensibilité : écrêtement du BMI

Afin de vérifier que les résultats ne sont pas portés par les valeurs extrêmes de BMI, le modèle principal est reproduit à l'identique en remplaçant `bmi` par `bmi_wins` (BMI écrêté aux 2,5 et 97,5 percentiles).

```
modele_bmi_wins <- glm(
  stroke ~ age + gender + hypertension + heart_disease + ever_married +
    work_type + Residence_type + avg_glucose_level + bmi_wins + smoking_status,
  data = donnees_adultes,
  family = binomial(link = "logit")
)

tbl_regression(modele_bmi_wins, exponentiate = TRUE) |>
  modify_header(label ~ "**Variable**") |>
  modify_caption("**Tableau 3.** Modèle avec IMC écrêté (analyse de sensibilité)")

or_brut <- exp(coef(modele_principal)["bmi"])
or_wins <- exp(coef(modele_bmi_wins)["bmi_wins"])
```

L'OR de l'IMC est de 1.002 dans le modèle principal (BMI brut) et de 1.003 avec le BMI écrêté. Les estimations des autres covariables sont comparables entre les deux modèles, ce qui suggère que les résultats sont peu sensibles aux valeurs extrêmes de cette variable.

Les estimations obtenues avec le BMI écrêté sont comparables à celles du modèle principal utilisant le BMI non écrêté, ce qui suggère que les résultats sont peu sensibles aux valeurs extrêmes de cette variable.

6.4 Représentation graphique des résultats

```
etiquettes <- c(
  age = "Âge",
  genderMale = "Sexe : Homme",
  hypertensionOui = "Hypertension",
  heart_diseaseOui = "Maladie cardiaque",
  ever_marriedYes = "Déjà marié(e)",
  work_typePrivate = "Emploi : Privé",
  `work_typeSelf-employed` = "Emploi : Indépendant",
  Residence_typeUrban = "Résidence : Urbaine",
  avg_glucose_level = "Glycémie moyenne",
```

Variable	OR	95% CI	p-value
age	1.08	1.07, 1.09	<0.001
gender			
Female	—	—	
Male	1.04	0.78, 1.37	0.8
hypertension			
Non	—	—	
Oui	1.49	1.07, 2.05	0.015
heart_disease			
Non	—	—	
Oui	1.32	0.90, 1.90	0.15
ever_married			
No	—	—	
Yes	0.82	0.53, 1.30	0.4
work_type			
Govt_job	—	—	
Private	1.16	0.78, 1.76	0.5
Self-employed	0.79	0.51, 1.27	0.3
Residence_type			
Rural	—	—	
Urban	1.09	0.83, 1.43	0.5
avg_glucose_level	1.00	1.00, 1.01	<0.001
bmi_wins	1.00	0.98, 1.03	0.8
smoking_status			
formerly smoked	—	—	
never smoked	0.82	0.58, 1.16	0.3
smokes	1.12	0.73, 1.70	0.6
Unknown	0.93	0.61, 1.39	0.7

Abbreviations : CI = Confidence Interval, OR = Odds Ratio

```

bmi      = "IMC",
`smoking_statusnever smoked` = "Tabac : jamais fumé",
smoking_statussmokes      = "Tabac : fumeur actuel",
smoking_statusUnknown     = "Tabac : inconnu"
)

resultats_modele <- tidy(modele_principal, exponentiate = TRUE, conf.int = TRUE) |>
  filter(term != "(Intercept)") |>
  mutate(term = recode(term, !!!etiquettes))

ggplot(resultats_modele, aes(x = estimate, y = fct_reorder(term, estimate))) +
  geom_vline(xintercept = 1, linetype = "dashed", color = "grey50") +
  geom_pointrange(aes(xmin = conf.low, xmax = conf.high)) +
  scale_x_log10() +
  labs(
    x = "Odds ratio (échelle log)",
    y = NULL,
    title = "Facteurs associés à l'AVC (modèle ajusté)"
  ) +
  theme_minimal()

```




FIGURE 3 : Odds ratios ajustés (IC 95%) du modèle principal

Ce graphe formalise le raisonnement qui a guidé la sélection des variables d'ajustement : l'âge est traité comme un facteur de confusion central, susceptible d'expliquer une partie des associations brutes observées pour l'hypertension, la maladie cardiaque, le statut marital et le type d'emploi. Les résultats du modèle ajusté (tableau 2) sont cohérents avec cette structure : les association fortement atténuée après ajustement, notamment pour l'âge (statut marital, type d'emploi) disparaissent après ajustement, tandis que au moins partiellement.

7 Discussion

7.1 Confrontation aux hypothèses

Âge (H1). L'association prédite se confirme et reste la plus forte du modèle ($OR = 1,08$ par année, $p < 0,001$). Elle persiste après ajustement, comme prévu.

Hypertension (H2). L'association reste significative après ajustement ($OR = 1,49$, $p = 0,015$), mais son intensité diminue par rapport à l'analyse brute. L'hypothèse d'une atténuation partielle par l'âge se vérifie, sans disparition complète de l'effet.

Glycémie moyenne (H3). L'association prédite se confirme. Exprimé par unité de mg/dL, l'OR est très proche de 1, ce qui reflète l'échelle de la variable plutôt qu'une absence d'effet réel : un écart de 1 mg/dL est cliniquement négligeable, alors qu'un écart plus important (par exemple 10 mg/dL) l'est davantage. Exprimé sur cette échelle, l'effet reste significatif mais modeste, sans permettre de conclure sur les mécanismes sous-jacents (âge, IMC, hypertension).

IMC (H4). Contrairement à la prédiction, aucune association significative n'est observée, ni avec le BMI brut ni avec le BMI écrêté — les deux versions donnent des résultats quasi identiques (analyse de sensibilité). L'hypothèse d'un effet propre de l'IMC sur l'AVC, indépendamment de l'hypertension et de la glycémie, n'est pas soutenue par ces données. Une relation non linéaire, évoquée comme possibilité en H4, n'a pas été testée ici et pourrait expliquer en partie cette absence d'effet.

Tabagisme (H5). Aucune des catégories n'est significativement associée à l'AVC après ajustement. L'hypothèse d'un effet propre du tabagisme n'est pas confirmée dans ce modèle.

Type d'emploi (H6). Conformément à la prédiction, aucune association forte ne persiste après ajustement. Cette variable se confirme comme peu informative pour expliquer l'AVC une fois l'âge pris en compte.

Type de résidence (H7). Aucune association observée, ni en brut ni en ajusté, conformément à la prédiction.

Statut matrimonial (H8). L'hypothèse se confirme : l'association observée en analyse univariée disparaît après ajustement sur l'âge ($OR = 0,82$, $p = 0,4$). Cela illustre bien le phénomène anticipé d'une association trompeuse portée par l'âge.

Maladie cardiaque (H9). L'association prédite comme forte s'atténue nettement après ajustement et devient non significative ($OR = 1,32$, $p = 0,15$). L'hypothèse prévoyait une atténuation partielle mais un effet résiduel important ; ce n'est pas ce qui est observé ici, l'âge semblant expliquer une grande partie de l'association brute — les patients porteurs d'une maladie cardiaque étant en moyenne plus âgés.

Genre (H10). Aucune différence significative entre hommes et femmes n'est observée dans le modèle ajusté ($OR = 1,04$, $p = 0,8$). L'hypothèse d'un effet médié par le tabagisme n'a donc pas lieu d'être testée, faute d'association de départ à expliquer.

7.2 Limites

La proportion d'AVC dans cet échantillon (5.8%) est très supérieure à la prévalence nationale française (2,0 %), ce qui suggère un mode d'échantillonnage non aléatoire. Les résultats doivent donc être interprétés comme des associations internes à cet échantillon, sans extrapolation à la population générale.

Le traitement des valeurs manquantes du BMI par imputation simple (médiane) constitue une autre limite : cette méthode réduit artificiellement la variance de la variable, ce qui peut conduire à sous-estimer son rôle réel.

Enfin, le caractère transversal des données ne permet pas d'établir de séquence temporelle entre les facteurs étudiés et la survenue de l'AVC, ce qui limite toute interprétation causale.

8 Conclusion

Dans cet échantillon, l'âge, l'hypertension et la glycémie moyenne restent associés au statut AVC après ajustement pour les covariables incluses dans le modèle. Les différences observées pour la maladie cardiaque et le statut matrimonial dans les analyses descriptives sont fortement atténuées après ajustement, notamment pour l'âge. Aucune association statistiquement mise en évidence n'est observée pour l'IMC, le tabagisme, le type d'emploi, le lieu de résidence ou le sexe. Compte tenu du caractère transversal des données, de l'absence d'information sur l'échantillonnage et de la temporalité incertaine des variables, ces résultats doivent être interprétés comme des associations internes à cet échantillon et non comme des effets causaux ou des estimations directement généralisables à une population cible.

Elm, Erik von, Douglas G. Altman, Matthias Egger, Stuart J. Pocock, Peter C. Gøtzsche, et Jan P. Vandenbroucke. 2007. « The Strengthening the Reporting of Observational Studies in Epidemiology (STROBE) Statement : Guidelines for Reporting Observational Studies ». *The Lancet* 370 (9596) : 1453-57. [https://doi.org/10.1016/S0140-6736\(07\)61602-X](https://doi.org/10.1016/S0140-6736(07)61602-X).

Gabet, Amélie, Yannick Béjot, Emmanuel Touzé, et al. 2025. « Épidémiologie des accidents vasculaires cérébraux en France ». *Bulletin épidémiologique hebdomadaire*, n HS : 23-38. https://beh.santepubliquefrance.fr/beh/2025/HS/2025_HS_3.html.